



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное автономное образовательное учреждение
высшего образования

**«Дальневосточный федеральный университет»
(ДФУ)**

**ИНСТИТУТ МАТЕМАТИКИ И КОМПЬЮТЕРНЫХ
ТЕХНОЛОГИЙ**

Лабораторная работа 7

Дисциплина «Теория вероятностей и математическая статистика»

Студент группы Б9123-01.03.02ии

Есакова Елизавета Михайловна

г. Владивосток

2025

https://colab.research.google.com/drive/1Tvdpmqv8JCNoWsx75KfazJWGmRs1qFZ1#scrollTo=ke_SHWvZrEqu

Критерий Колмогорова нужен для проверки гипотезы о том, что выборка из заданного распределения. Для непрерывных распределений.

Дано

Случайная выборка $X_1, X_2, \dots, X_n$ из X .

Гипотезы

$H_0 : F_X = F;$

$H_1 : F_X \neq F.$

Пусть $\hat{F}_n(x)$ – эмпирическая функция распределения случайной величины X . И определена статистика

$$D_n = \sup_{x \in \mathbb{R}} \left| \hat{F}_n(x) - F_X(x) \right|,$$

тогда

$$\sqrt{n}D_n \rightsquigarrow K,$$

где $F_K(x) = \sum_{k=-\infty}^{+\infty} (-1)^k e^{-2k^2 x^2} \cdot I(x > 0).$

$F_X(x)$ - теоретическая функция распределения

Асимптотическое распределение статистики $\sqrt{n}D_n$ при $n \rightarrow \infty$ задается функцией Колмогорова $F_K(x)$

p-значение

$$p = 1 - F_K(k).$$

Код:

```
'''критерий Колмогорова'''

import numpy as np

def kolmogorov(sample, cdf):

    n = len(sample)
```

```

sample_sorted = np.sort(sample)
y = np.arange(1, n + 1) / n # ЭФР

cdf_values = cdf(sample_sorted)

# Вычисление статистики D_n
D_plus = np.max(y - cdf_values)
D_minus = np.max(cdf_values - (y - 1 / n))
D_n = max(D_plus, D_minus)

# Асимптотическое распределение Колмогорова
kv_n_D = np.sqrt(n) * D_n
p_value = 1 - k_cdf(kv_n_D)

return p_value

def k_cdf(x, terms=100):
    if x <= 0:
        return 0.0

    total = 0.0
    for k in range(-terms, terms + 1):
        term = (-1)**k * np.exp(-2 * k**2 * x**2)
        total += term

    return total

```

в Сципай:

```

print("Колмогоров (scipy):", stats.kstest(sample1, 'uniform', args=(0,
1)) [1])

```

Для дискретных распределений:

Распределение χ^2

Пусть случайные величины $X_1, X_2, \dots, X_n \sim N(0; 1)$ независимы. Тогда случайная величина

$$\sum_{i=1}^n X_i^2 = X \sim \chi^2(n)$$

имеет распределение χ^2 с n степенями свободы.

Плотность распределения $\chi^2(n)$

$$f_X(x) = \frac{x^{\frac{n}{2}-1} e^{-\frac{x}{2}}}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)}.$$

Критерий хи-квадрат проверяет гипотезу о том, что случайная выборка $X_1, X_2, \dots, X_n$ происходит из заданного распределения X .

Дано

Случайная выборка $X_1, X_2, \dots, X_n$ из X .

Гипотезы

$H_0: F_X = F;$

$H_1: F_X \neq F.$

Статистика:

n_i – наблюдаемая частота

np_i – ожидаемая частота

p_i – вероятность попадания в i -й интервал по теоретическому распределению

$$\chi_{k-1}^2 = \sum_{i=1}^n \frac{(n_i - np_i)^2}{np_i} \sim \chi^2(k-1).$$

p -значение

$$p = 1 - F_{\chi_{k-1}^2}(\chi^2).$$

Код:

```
'''критерий хи-квадрат'''

def chi_test(sample, bins, cdf):
    observed, _ = np.histogram(sample, bins=bins)
    n = len(sample)
    k = len(bins) - 1

    # Вычисляем ожидаемые частоты
    chastot = []
    for i in range(k):
        p = cdf(bins[i+1]) - cdf(bins[i])
        chastot.append(n * p)
    chastot = np.array(chastot)

    chi2_stat = np.sum((observed - chastot)**2 / chastot)

    p_value = 1 - stats.chi2.cdf(chi2_stat, df=k-1)

    return p_value
```

В Сципай:

```
print("χ-квадрат (scipy):", chisquare(np.histogram(sample1, bins=bins)[0],
f_exp=len(sample1)*np.diff(uniform.cdf(bins, loc=0, scale=1)))[1])
```

Критерий Колмогорова-Смирнова

Дано

2 случайные выборки $X_1, X_2, \dots, X_n$ из X и $Y_1, Y_2, \dots, Y_m$ из Y .

Гипотезы

$H_0 : F_X = F_Y;$

$H_1 : F_X \neq F_Y.$

Проверяет, происходят ли две выборки из одного и того же распределения

Статистика

$$K = \sqrt{\frac{n \cdot m}{n+m}} \cdot \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - \hat{F}_m(x)|.$$

p -значение

$$p = 1 - F_K(k).$$

```
'''критерий Колмогорова-Смирнова'''
def kolmogorov_smirnov(sample1, sample2):

    n = len(sample1)
    m = len(sample2)

    oba_sorted = np.sort(np.concatenate([sample1, sample2]))

    ecdf1 = np.searchsorted(np.sort(sample1), oba_sorted, side='right') /
n
    ecdf2 = np.searchsorted(np.sort(sample2), oba_sorted, side='right') /
m

    K = np.sqrt((n * m) / (n + m)) * np.max(np.abs(ecdf1 - ecdf2))

    p_value = 0
    for k in range(1, 100):
        p_value += (-1)**(k-1) * np.exp(-2 * k**2 * K**2)
    p_value = 2 * p_value

    return p_value
```

В Сципай: `print("\n 1 и 3 (scipy):", ks_2samp(sample1, sample3)[1])`

4. Вычислите остаток от деления своего номера в списке группы на 3. Это номер распределения: 0) нормальное, 1) равномерное, 2) биномиальное. Из распределения сгенерируйте 3 выборки. Две с одинаковыми параметрами распределения, а третью с другими.

```
'''Распределение'''

ost = 4 % 3

if ost==0:
    print('мое нормальное')
elif ost==1:
    print('мое равномерное')
elif ost==2:
    print('мое биномиальное')

np.random.seed(4)
sample1 = uniform.rvs(loc=0, scale=1, size=100)
sample2 = uniform.rvs(loc=0, scale=1, size=100)
sample3 = uniform.rvs(loc=4, scale=5, size=100)

мое равномерное
```

5. Проверьте гипотезы: 1) ваша выборка (какая-то одна) имеет то распределение, откуда она взялась (по Колмогорову для непрерывных распределений и по хи квадрат для дискретных);

```
print("\nКолмогоров :", kolmogorov(sample1, lambda x: uniform.cdf(x, loc=0, scale=1)))

print("Колмогоров (scipy):", stats.kstest(sample1, 'uniform', args=(0, 1))[1])

bins = np.linspace(0, 1, 6) # границы интервалов разбиения
print("\nХи-квадрат:", chi_test(sample1, bins, lambda x: uniform.cdf(x, loc=0, scale=1)))
print("Хи-квадрат (scipy):", chisquare(np.histogram(sample1, bins=bins)[0],
                                     f_exp=len(sample1)*np.diff(uniform.cdf(bins, loc=0, scale=1)))[1])

Колмогоров : 0.24065813438328343
Колмогоров (scipy): 0.22470633444802351

Хи-квадрат: 0.2977128734228288
Хи-квадрат (scipy): 0.2977128734228288
```

2) ваша выборка имеет какое-то другое конкретное распределение (теми же критериями);

```
print("\nНормальное распределение N(0.4, 0.1)")

print("\nКолмогоров:", kolmogorov(sample1, lambda x: norm.cdf(x, loc=0.4, scale=0.1)))
print("\nКолмогоров (scipy):", stats.kstest(sample1, 'norm', args=(0.4, 0.1))[1])
```

Нормальное распределение N(0.4, 0.1)

Колмогоров: 2.220446049250313e-15

Колмогоров (scipy): 4.268590848337841e-16

3) для каждой пары выборок гипотезу однородности;

```
print("\ndля каждой пары выборок проверить гипотезу однородности")

print("\n 1 и 2:", kolmogorov_smirnov(sample1, sample2))
print("\n 1 и 2 (scipy):", ks_2samp(sample1, sample2)[1])

print("\n 1 и 3:", kolmogorov_smirnov(sample1, sample3))
print("\n 1 и 3 (scipy):", ks_2samp(sample1, sample3)[1])

print("\n 2 и 3:", kolmogorov_smirnov(sample2, sample3))
print("\n 2 и 3 (scipy):", ks_2samp(sample2, sample3)[1])
```

для каждой пары выборок проверить гипотезу однородности

1 и 2: 0.3667210855537612

1 и 2 (scipy): 0.36818778606286096

1 и 3: 7.440151952041566e-44

1 и 3 (scipy): 2.2087606931995054e-59

2 и 3 7.440151952041566e-44

2 и 3 (scipy): 2.2087606931995054e-59

4) нормальность распределения по критерию Шапиро-Вилка (библиотечный).
Для гипотез 1-3 сверьте результат с библиотечными тестами

```
print("\n Шапиро-Вилк")
print("\n 1:", shapiro(sample1)[1])
print("\n 2 :", shapiro(sample2)[1])
print("\n 3 :", shapiro(sample3)[1])
```

Шапиро-Вилк

1: 0.006553563996544812

2 : 6.871212675676921e-05

3 : 0.001233449702313176

Критерий Шапиро-Вилка — это статистический тест, используемый для проверки гипотезы о нормальности распределения данных. Если значение p высокое, то набор данных имеет нормальное распределение, а низкое значение p указывает на то, что он не имеет нормального распределения.

